Oficina de R Básico

R-Ladies São Paulo

02/02/2019

R-Ladies São Paulo

Cronograma de hoje

- Data Science
- Introdução ao ambiente R
- O pacote Tidyverse
- Desafios hands-on
- Para aprender mais

O que é Data Science?

Data Science ou **Ciência de Dados** é uma ciência interdisciplinar sobre o processamento de grandes conjuntos de dados usando métodos estatísticos para extrair insights sobre os dados brutos.

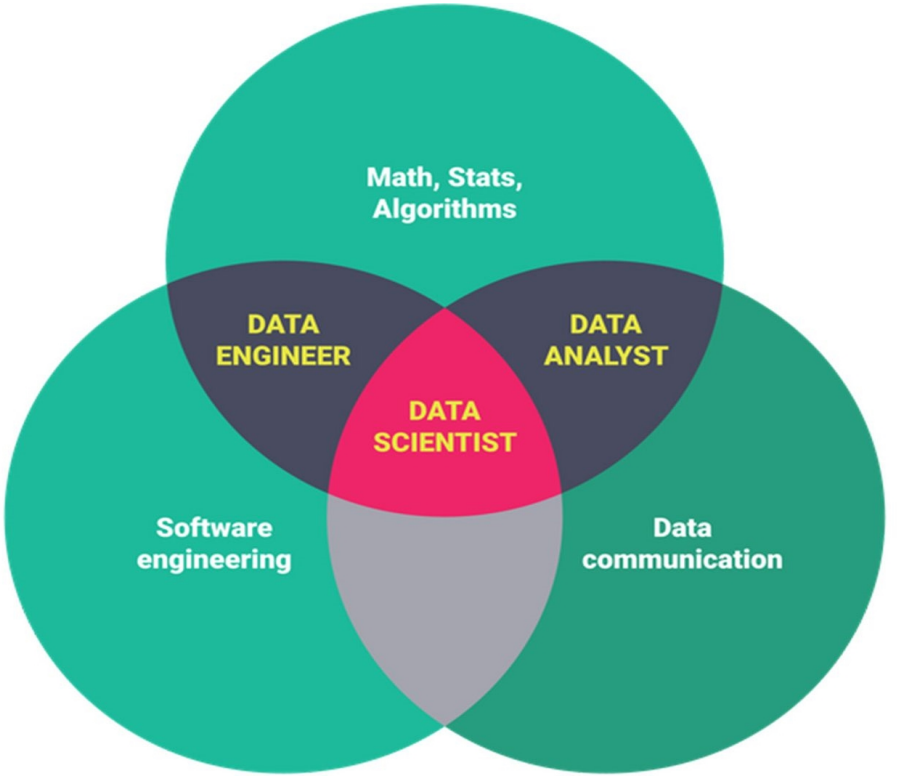

Ciclo da Ciência de Dados

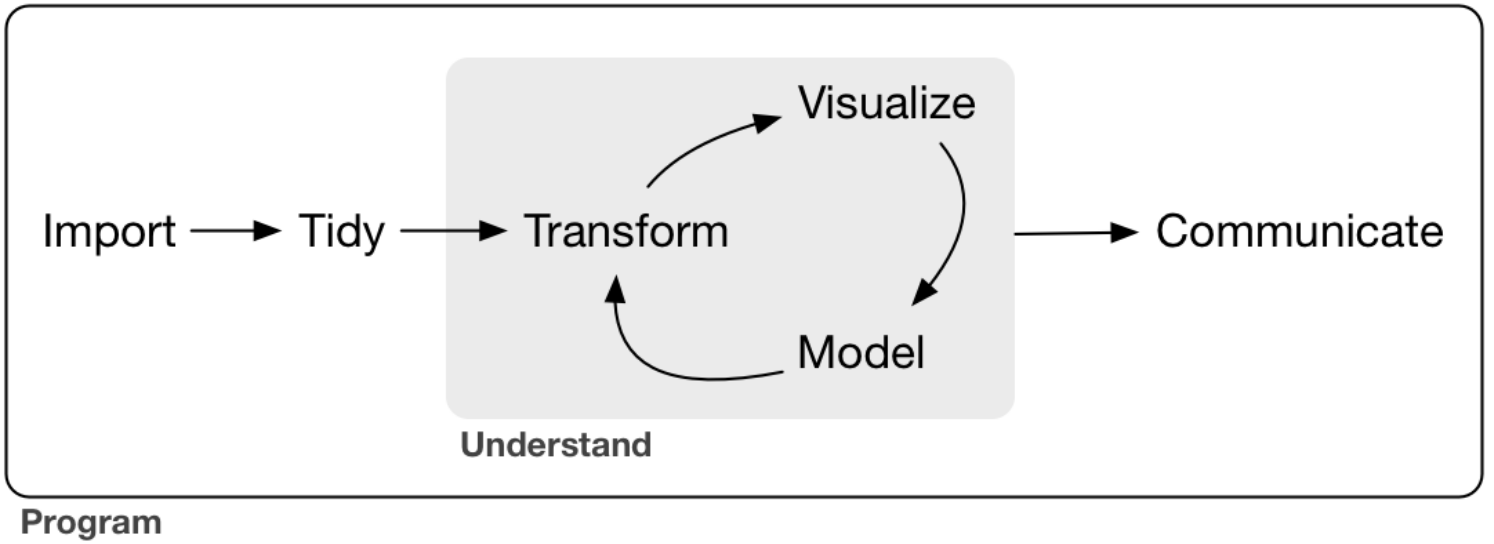

Fonte: R For Data Science

Ciência de Dados

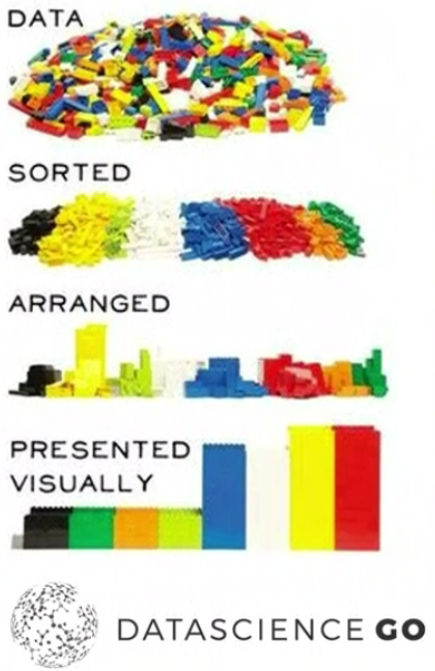

Fonte: slide do Randy Lao na Conferência Data Science Go 2018

Por que usar o R?

- É uma linguagem de programação para análise de dados
- É open source
- Possui uma comunidade ativa de desenvolvedores
- É flexível, permitindo desenvolver funções e pacotes para facilitar o trabalho
- Está disponível em diferentes plataformas: Windows, Linux e Mac

R Básico

Instalação R e R Studio

Escolha a versão para o seu sistema operacional

- Instalação do R
- Instalação do R Studio

RStudio

RStudio é o IDE da Linguagem R, ou seja, o ambiente que utilizamos para editar e executar os códigos em R.

Tem quatro áreas, conforme a figura abaixo:

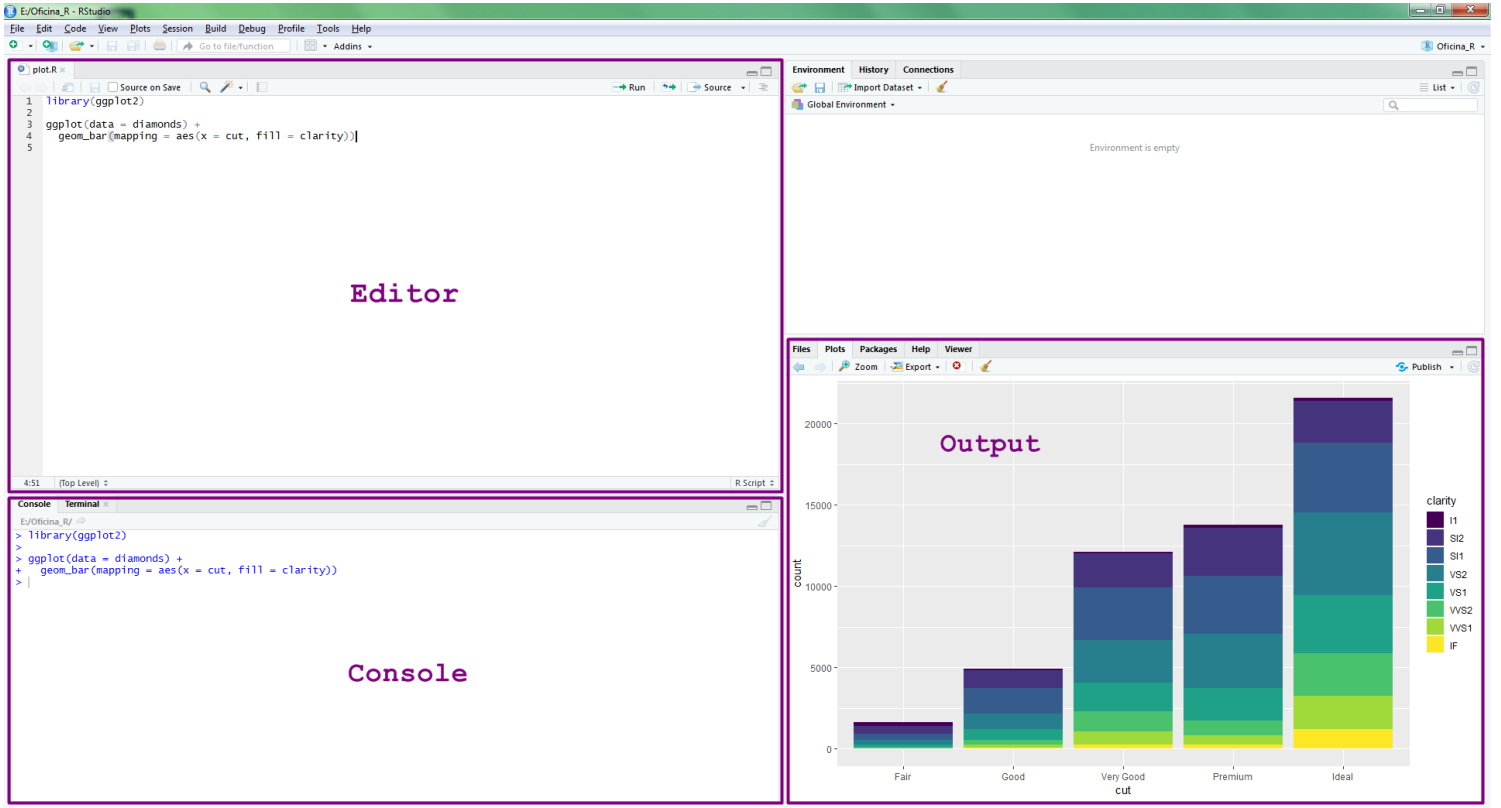

Help!

- Pedir ajuda: **help**(nome_da_funcao) ou **?**nome_da_funcao.

```
help(sum)
?sum
```

- Se a dúvida permanecer, procure no Stack OverFlow, Google.
  - E se ainda tiver dúvidas, pergunte para a comunidade (há grupos no Telegram e outras redes sociais).

Pacotes no R

Pacotes são coleções de funções, dados e documentação que estendem as capacidades do R básico.

Eles precisam ser instalados e carregados.

Instalação de Pacotes:

- Via CRAN: install.packages("nome-do-pacote").

```
install.packages("tidyverse")
```

- Via Github: devtools::install_github("nome-do-repo/nome-do-pacote").

```
devtools::install_github("tidyverse/dplyr")
```

Carregar pacotes:

- library(nome-do-pacote)

```
library(tidyverse)
```

Dicas sobre Pacotes

1. Você só precisa instalar o pacote uma vez, mas precisa carregá-lo sempre que começar uma nova sessão;

2. Para instalar o pacote use as aspas;

3. Para carregar o pacote, **não** utilize as aspas.

RMarkdown

No R é possível criar documentos que podem, por exemplo, explicar os dados em textos e também apresentar os códigos e os resultados destes. Tudo em um só lugar.

RMarkdown é um documento que contém textos e códigos em R.

O trecho de código do RMarkdown é chamado de **chunk**.

Atalho para criar um chunck: CTRL + ALT + I

Atalhos importantes

Os atalhos facilitam. Veja os principais:

- CTRL + ENTER: roda a linha selecionada no script.
- ALT + **-**: (<-) sinal de atribuição.
- CTRL + SHIFT + M: (%>%) operador pipe.
- CTRL + ALT + I: cria um chunk do RMarkdown.

R como calculadora

```r
2 + 5    # adição
```

```
## [1] 7
```

```r
9 - 4    # subtração
```

```
## [1] 5
```

```r
5 * 2    # multiplicação
```

```
## [1] 10
```

```r
7 / 5    # divisão
```

```
## [1] 1.4
```

R como calculadora

```
9 %% 4   # resto da divisão de 9 por 4
```

```
## [1] 1
```

```
7 %/% 4  # parte inteira da divisão de 4 por 3
```

```
## [1] 1
```

```
8 ^ 2    # potenciação
```

```
## [1] 64
```

```
sqrt(1024) # radiciação
```

```
## [1] 32
```

A ordem matemática das operações também vale no R.

Nomes de objetos e variáveis

- Os nomes devem começar com uma letra. Podem conter letras, números, _ e .
- Recomendação do autor do livro R For Data Science: **usar_snake_case**, ou seja, palavras escritas em minúsculo separadas pelo underscore (_).
- O R é *case sensitive*, isto é, faz a diferenciação entre as letras minúsculas e maiúsculas. Portanto, um objeto chamado *teste* é diferente de um outro objeto chamado *Teste*.

Criando objetos no R

- Para atribuir um valor a um objeto no R, utilizamos o operador **<-**
- O atalho ALT + **-** gera o operador **<-**
- Todas as declarações R onde são criados objetos atribuindo valores a eles, tem a mesma forma:

nome_do_objeto <- valor

Exemplos de objetos e atribuição de valores

```
nome_empregado <- "Tom Cruise de Souza e Silva"
nome_empregado
```

```
## [1] "Tom Cruise de Souza e Silva"
```

```
horas_trabalhadas <- 160
horas_trabalhadas
```

```
## [1] 160
```

```
salario <- 3984.23
salario
```

```
## [1] 3984.23
```

```
ativo <- TRUE
ativo
```

```
## [1] TRUE
```

Classes Básicas ou Atômicas do R

- **Character**: texto
- **Integer**: números inteiros
- **Numeric**: números racionais
- **Complex**: números complexos (raramente usados para Análise de Dados)
- **Logical**: TRUE, FALSE ou NA
- **Factor**: variavéis categóricas

Exemplos: character

```
"escola"
```

```
## [1] "escola"
```

```
"2019"
```

```
## [1] "2019"
```

```
"I love pinschers."
```

```
## [1] "I love pinschers."
```

Exemplos: integer

```
10L #Um número inteiro pode ser representado acompanhado de um L
```

```
## [1] 10
```

```
2019L
```

```
## [1] 2019
```

Exemplos: numeric

```
10
```

```
## [1] 10
```

```
2019
```

```
## [1] 2019
```

```
5.44
```

```
## [1] 5.44
```

Exemplos: complex

```
4 + 9i
```

```
## [1] 4+9i
```

Exemplos: logical

```
TRUE
```

```
## [1] TRUE
```

```
FALSE
```

```
## [1] FALSE
```

Exemplos: factor

```
escolaridade <- c("Médio", "Superior", "Fundamental", "Fundamental", "Médio")
fator <- as.factor(escolaridade)
fator
```

```
## [1] Médio       Superior    Fundamental Fundamental Médio
## Levels: Fundamental Médio Superior
```

A função as.factor() criou um objeto do tipo factor.

Na linha *Levels* aparecem os rótulos do fator.

Essa classe de dados pode ser trabalhada com o pacote **forcats**.

Função class:

A função **class** mostra a classe de um objeto.

```
nome_filme <- "Bohemian Rhapsody"
class(nome_filme)
```

```
## [1] "character"
```

```
ano_inteiro <- 2018L
class(ano_inteiro)
```

```
## [1] "integer"
```

```
ano <- 2018
class(ano)
```

```
## [1] "numeric"
```

Função class

```
motor <- 1.5
class(motor)
```

```
## [1] "numeric"
```

```
passou_enem <- TRUE
class(passou_enem)
```

```
## [1] "logical"
```

Tipos de objetos:

- **Vector**: armazena elementos de mesma classe.
- **Matrix**: vetores de duas dimensões que armazenam elementos de mesma classe.
- **List**: tipo especial de vetor que aceita elementos de classes diferentes.
- **Data.frame**: são tabelas de dados com linhas e colunas, como uma tabela do Excel. Como são listas, essas colunas podem ser de classes diferentes.

Exemplo: Vector

A função c() cria um vetor.

```
semestre1 <- c("janeiro", "fevereiro", "março", "abril", "maio", "junho")
notas_alunos <- c(5, 6.5, 10, 0.5, 2.75, 3, 9)
```

É possível realizar operações com vetores.

```
vetor1 <- 1:5
vetor1 / 5   #Objeto vetor1 dividido por 5
```

```
## [1] 0.2 0.4 0.6 0.8 1.0
```

```
vetor2 <- 6:10
vetor1 * vetor2
```

```
## [1]  6 14 24 36 50
```

Exemplo: Matrix

A função matrix() cria uma matriz.

```
primeira_matriz <- matrix(1:8, nrow = 2, ncol = 4)
primeira_matriz
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    1    3    5    7
## [2,]    2    4    6    8
```

A função dim() retorna a dimensão do objeto (linha e coluna).

```
dim(primeira_matriz)
```

```
## [1] 2 4
```

Exemplo: List

A função list() cria uma lista.

```
wizards <- list("Harry Potter", 18, TRUE, c("Hermione Granger", "Rony Weasley"))
class(wizards)
```

```
## [1] "list"
```

A função is.list() verifica se o objeto é ou não uma lista.

```
harry_friends <- c("Hermione Granger", "Rony Weasley")
class(harry_friends)
```

```
## [1] "character"
```

```
is.list(harry_friends)
```

```
## [1] FALSE
```

Exemplo: Data.frame

A função head() mostra as primeiras 6 linhas do dataframe.

```
df <- starwars

head(df)
```

```
## # A tibble: 6 x 13
##   name  height  mass hair_color skin_color eye_color birth_year gender
##   <chr>  <int> <dbl> <chr>      <chr>      <chr>           <dbl> <chr>
## 1 Luke~    172    77 blond      fair       blue             19   male
## 2 C-3PO    167    75 <NA>       gold       yellow          112   <NA>
## 3 R2-D2     96    32 <NA>       white, bl~ red              33   <NA>
## 4 Dart~    202   136 none       white      yellow           41.9 male
## 5 Leia~    150    49 brown      light      brown            19   female
## 6 Owen~    178   120 brown, gr~ light      blue             52   male
## # ... with 5 more variables: homeworld <chr>, species <chr>, films <list>,
## #   vehicles <list>, starships <list>
```

Tibble é uma releitura moderna do data.frame.

Funções úteis para trabalhar com dataframes

- tail(): mostra as últimas 6 linhas.
- names(): mostra os nomes das colunas.
- glimpse(): mostra várias informações sobre o Tibble, como o número de observações (linhas) e variáveis (colunas), o nome das colunas e o tipo delas.

Conversão de classes:

Podemos forçar um objeto a ser de uma classe específica com as funções:

- as.character()
- as.numeric()
- as.integer()
- as.logical()

Exemplo de conversão de classes

```
vetor <- 0:9
vetor
```

```
##  [1] 0 1 2 3 4 5 6 7 8 9
```

```
class(vetor)
```

```
## [1] "integer"
```

```
vetor_numeric <- as.numeric(vetor)
vetor_numeric
```

```
##  [1] 0 1 2 3 4 5 6 7 8 9
```

```
class(vetor_numeric)
```

```
## [1] "numeric"
```

Exemplo de conversão de classes

```
vetor_character <- as.character(vetor)
vetor_character
```

```
##  [1] "0" "1" "2" "3" "4" "5" "6" "7" "8" "9"
```

```
class(vetor_character)
```

```
## [1] "character"
```

```
vetor_logical <- as.logical(vetor)
vetor_logical
```

```
##  [1] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
```

```
class(vetor_logical)
```

```
## [1] "logical"
```

Operadores Lógicos

- Igual a: **==**
- Diferente de: **!=**
- Maior que: **>**
- Maior ou igual: **>=**
- Menor que: **<**
- Menor ou igual: **<=**
- Negação: **!**
- E: **&**
- OU: **|**

NA

Uma característica importante do R que pode dificultar a comparação são os valores ausentes ou **NAs** (não disponíveis).

NA representa um valor desconhecido.

NA

Quase qualquer operação envolvendo um valor desconhecido também será desconhecido:

```
NA > 10
```

```
## [1] NA
```

```
10 == NA
```

```
## [1] NA
```

```
NA + 10
```

```
## [1] NA
```

```
NA / 2
```

```
## [1] NA
```

NA

E o mais confuso:

```
NA == NA
```

```
## [1] NA
```

is.na() é a função que testa se um objeto é NA.

Estrutura Condicional: IF

```
mes <- "Novembro"

if(mes == "Novembro") {
  print("O Natal é mês que vem!") # mostra essa mensagem.
}
```

```
## [1] "O Natal é mês que vem!"
```

Estrutura Condicional: IF e ELSE

```
mes <- "Dezembro"

if(mes == "Novembro") {

  print("O Natal é mês que vem!") # mostra essa mensagem.

} else if(mes == "Dezembro") {

  print("O Natal chegou!") # mostra essa mensagem.
}
```

```
## [1] "O Natal chegou!"
```

Estrutura de Repetição: FOR

Imprime os 10 primeiros nomes dos personagens da base starwars usando o laço for.

```
df <- starwars

lista_personagens <- head(df$name, 10)

for(i in seq_along(lista_personagens)) {
  print(lista_personagens[i])
}
```

```
## [1] "Luke Skywalker"
## [1] "C-3PO"
## [1] "R2-D2"
## [1] "Darth Vader"
## [1] "Leia Organa"
## [1] "Owen Lars"
## [1] "Beru Whitesun lars"
## [1] "R5-D4"
## [1] "Biggs Darklighter"
## [1] "Obi-Wan Kenobi"
```

Tidyverse

O Tidyverse

É uma coleção de pacotes R projetados para a ciência de dados. Todos os pacotes compartilham uma mesma filosofia de desenvolvimento, sintaxe e estruturas de dados.

Pacotes do Tidyverse

- **ggplot2**: cria gráficos
- **dplyr**: manipulação de dados
- **tidyr**: arruma os dados
- **readr**: leitura dos dados
- **purrr**: ferramentas para programação funcional, trabalha com funções e vetores
- **tibble**: dataframes moderno, mais simples de manipular
- **magrittr**: facilita a escrita e leitura do código
- **stringr**: trabalha com strings
- **forcats**: trabalha com fatores
- **lubridate**: trabalha com datas

dplyr

A ideia do pacote **dplyr** é tornar a manipulação de dados explícita utilizando verbos que indicam a ação a ser realizada.

O encadeamento dos verbos com o banco de dados é realizado com o operador **pipe**: **%>%**

O dplyr foi desenhado para trabalhar com o operator pipe **%>%** do pacote magritrr.

Os 6 verbos do dplyr

- **filter**(): seleciona linhas
- **arrange**(): ordena de acordo com uma ou mais colunas
- **select**(): seleciona colunas
- **mutate**(): cria/modifica colunas
- **summarise**(): sumariza/agrega colunas
- **group_by**(): agrupa colunas

O operador %>%, o Pipe

Imagine uma receita que tenha as instruções: junte os ingredientes, misture e leve ao forno. Na forma usual do R, essas instruções provavelmente seriam assim:

forno(misture(junte(ingredientes)))

Dessa forma temos que pensar “de dentro para fora”. O primeiro comando que lemos é forno, sendo que essa é a última operação que será realizada.

Com o operador pipe seria algo assim:

ingredientes %>% junte %>% misture %>% forno

É mais intuitivo!

O operador %>%, o Pipe

Para ficar mais fácil: pense no Pipe %>% como um operador que efetua as operações à direita nos valores que estão à esquerda.

Ou ainda, o operador %>% passa o que está à esquerda como argumento para a operação da direita.

Atalho: CTRL + SHIFT + M

Importação de arquivos

Pacote **readr**: funções para ler arquivos texto

- read_csv
- read_csv2
- read_delim
- read_log
- read_rds

Pacote **readxl**: função para ler arquivo Excel

- read_excel

Pacote **haven**: funções para ler outros softwares estatísticos

- read_sas
- read_spss
- read_stata

E lá vamos nós!

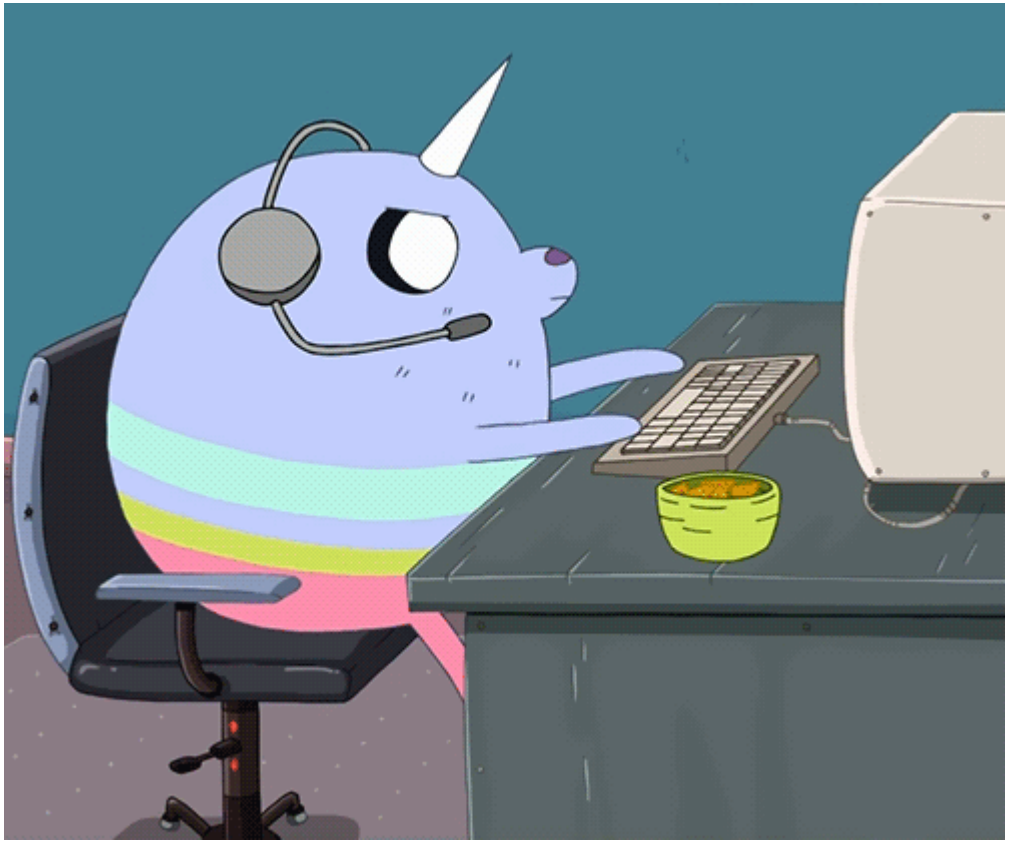

Instruções

- Abrir o RStudio da sua máquina
- Fazer o download da pasta: github.com/xxxx/xxxx
- Descompactar na pasta Documentos
- Abrir o arquivo oficina_R_basico.Rproj
- Abrir um novo R script (file, new file, R script)

Importação de arquivos

```
library(tidyverse)

# Uma outra opção é carregar somente o(s) pacote(s) que irá utilizar.
#library(dplyr)

# Importa o arquivo csv para o objeto df_titanic
df_titanic <- read_csv("data/titanic.csv")
```

View e glimpse

- Para visualizar um objeto: **View**(nome-do-objeto)
- **glimpse()**: mostra informações como o número de observações (linhas) e variáveis (colunas), o nome das colunas, o tipo delas e os primeiros dados de cada coluna.

```
df_titanic %>% glimpse()
```

```
## Observations: 891
## Variables: 12
## $ id_passageiro  <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, ...
## $ sobreviveu     <chr> "nao", "sim", "sim", "sim", "nao", "nao", "nao"...
## $ classe         <int> 3, 1, 3, 1, 3, 3, 1, 3, 3, 2, 3, 1, 3, 3, 3, 2,...
## $ nome           <chr> "Braund, Mr. Owen Harris", "Cumings, Mrs. John ...
## $ sexo           <chr> "masculino", "feminino", "feminino", "feminino"...
## $ idade          <dbl> 22, 38, 26, 35, 35, NA, 54, 2, 27, 14, 4, 58, 2...
## $ irmaos_conjuge <int> 1, 1, 0, 1, 0, 0, 0, 3, 0, 1, 1, 0, 0, 1, 0, 0,...
## $ pais_criancas  <int> 0, 0, 0, 0, 0, 0, 0, 1, 2, 0, 1, 0, 0, 5, 0, 0,...
## $ passagem       <chr> "A/5 21171", "PC 17599", "STON/O2. 3101282", "1...
## $ tarifa         <dbl> 7.2500, 71.2833, 7.9250, 53.1000, 8.0500, 8.458...
## $ cabine         <chr> NA, "C85", NA, "C123", NA, NA, "E46", NA, NA, N...
## $ embarque       <chr> "Southampton", "Cherbourg", "Southampton", "Sou...
```

filter

Selecionar linhas da base de dados.

```
# Seleciona os sobreviventes.
df_titanic %>% filter(sobreviveu == "sim")
```

```
## # A tibble: 342 x 12
##    id_passageiro sobreviveu classe nome  sexo  idade irmaos_conjuge
##            <int> <chr>       <int> <chr> <chr> <dbl>          <int>
##  1             2 sim             1 Cumi~ femi~    38              1
##  2             3 sim             3 Heik~ femi~    26              0
##  3             4 sim             1 Futr~ femi~    35              1
##  4             9 sim             3 John~ femi~    27              0
##  5            10 sim             2 Nass~ femi~    14              1
##  6            11 sim             3 Sand~ femi~     4              1
##  7            12 sim             1 Bonn~ femi~    58              0
##  8            16 sim             2 Hewl~ femi~    55              0
##  9            18 sim             2 Will~ masc~    NA              0
## 10            20 sim             3 Mass~ femi~    NA              0
## # ... with 332 more rows, and 5 more variables: pais_criancas <int>,
## #   passagem <chr>, tarifa <dbl>, cabine <chr>, embarque <chr>
```

Tibble é uma releitura moderna do data.frame.

filter

```r
# Cria um objeto e atribui a ele as linhas com os sobreviventes.
sobreviventes <- df_titanic %>% filter(sobreviveu == "sim")


# Crianças com menos de 12 anos que sobreviveram.
criancas_sobreviventes <- df_titanic %>% filter(sobreviveu == "sim" & idade < 12)


# Embarque realizado nos locais: Southampton ou Queenstow.
embarque <- df_titanic %>% filter(embarque == "Southampton" |
                                  embarque == "Queenstow")


# A instrução acima pode ser reescrita com o operador %in%:
embarque <- df_titanic %>% filter(embarque %in% c("Southampton", "Queenstow"))
```

filter

```r
# Pessoas sem informação de local de embarque.
# is.na() - função que retorna TRUE se o valor for NA e FALSE se não for.
sem_embarque <- df_titanic %>% filter(is.na(embarque))



# Pessoas que tem "Elizabeth" em qualquer posição do campo nome.
# str_detect - função que retorna TRUE se detectou o valor dado e
# FALSE, caso não tenha encontrado.
nome <- df_titanic %>% filter(str_detect(nome, "Elizabeth"))
```

Desafio 1

1) Criar um objeto chamado passageiras que seleciona somente as passageiras.

2) Criar um objeto chamado criancas_Cherbourg que seleciona as crianças com menos de 12 anos que embarcaram na cidade de Cherbourg.

arrange

Ordenar as linhas da base de dados conforme uma ou mais variáveis.

```
# Ordena por ordem crescente da coluna nome.
passageiros_ordenados <- df_titanic %>% arrange(nome)
passageiros_ordenados
```

```
## # A tibble: 891 x 12
##    id_passageiro sobreviveu classe nome  sexo  idade irmaos_conjuge
##            <int> <chr>       <int> <chr> <chr> <dbl>          <int>
##  1           846 nao             3 Abbi~ masc~    42              0
##  2           747 nao             3 Abbo~ masc~    16              1
##  3           280 sim             3 Abbo~ femi~    35              1
##  4           309 nao             2 Abel~ masc~    30              1
##  5           875 sim             2 Abel~ femi~    28              1
##  6           366 nao             3 Adah~ masc~    30              0
##  7           402 nao             3 Adam~ masc~    26              0
##  8            41 nao             3 Ahli~ femi~    40              1
##  9           856 sim             3 Aks,~ femi~    18              0
## 10           208 sim             3 Albi~ masc~    26              0
## # ... with 881 more rows, and 5 more variables: pais_criancas <int>,
## #   passagem <chr>, tarifa <dbl>, cabine <chr>, embarque <chr>
```

arrange

É possível ordenar na ordem descrescente e também por mais de uma variável.

```
# Ordena por ordem decrescente de idade e por ordem crescente de nome.
passageiros_ordenados <- df_titanic %>% arrange(desc(idade), nome)
passageiros_ordenados
```

```
## # A tibble: 891 x 12
##    id_passageiro sobreviveu classe nome  sexo  idade irmaos_conjuge
##            <int> <chr>       <int> <chr> <chr> <dbl>          <int>
##  1           631 sim             1 Bark~ masc~  80                0
##  2           852 nao             3 Sven~ masc~  74                0
##  3           494 nao             1 Arta~ masc~  71                0
##  4            97 nao             1 Gold~ masc~  71                0
##  5           117 nao             3 Conn~ masc~  70.5              0
##  6           746 nao             1 Cros~ masc~  70                1
##  7           673 nao             2 Mitc~ masc~  70                0
##  8            34 nao             2 Whea~ masc~  66                0
##  9           281 nao             3 Duan~ masc~  65                0
## 10           457 nao             1 Mill~ masc~  65                0
## # ... with 881 more rows, and 5 more variables: pais_criancas <int>,
## #   passagem <chr>, tarifa <dbl>, cabine <chr>, embarque <chr>
```

filter & arrange

```
# Filtra os sobreviventes homens e ordena por classe.
df_titanic  %>%
  filter(sexo == "masculino" & sobreviveu == "sim") %>%
  arrange(classe)
```

```
## # A tibble: 109 x 12
##    id_passageiro sobreviveu classe nome  sexo  idade irmaos_conjuge
##            <int> <chr>       <int> <chr> <chr> <dbl>          <int>
##  1            24 sim             1 Slop~ masc~ 28                 0
##  2            56 sim             1 Wool~ masc~ NA                 0
##  3            98 sim             1 Gree~ masc~ 23                 0
##  4           188 sim             1 "Rom~ masc~ 45                 0
##  5           210 sim             1 Blan~ masc~ 40                 0
##  6           225 sim             1 Hoyt~ masc~ 38                 1
##  7           249 sim             1 Beck~ masc~ 37                 1
##  8           299 sim             1 Saal~ masc~ NA                 0
##  9           306 sim             1 Alli~ masc~  0.92              1
## 10           371 sim             1 Hard~ masc~ 25                 1
## # ... with 99 more rows, and 5 more variables: pais_criancas <int>,
## #   passagem <chr>, tarifa <dbl>, cabine <chr>, embarque <chr>
```

Desafio 2

1) Ordenar os passageiros por ordem decrescente de classe e nomeie o objeto.

2) Ordenar somente as passageiras por ordem de idade e dê um nome para o objeto.

select

Selecionar colunas (variáveis) da base de dados.

```
# Seleciona as colunas indicadas.
df_titanic %>% select(nome, idade, classe, embarque)
```

```
## # A tibble: 891 x 4
##    nome                                              idade classe embarque
##    <chr>                                             <dbl>  <int> <chr>
##  1 Braund, Mr. Owen Harris                              22      3 Southampt~
##  2 Cumings, Mrs. John Bradley (Florence Briggs Th~      38      1 Cherbourg
##  3 Heikkinen, Miss. Laina                               26      3 Southampt~
##  4 Futrelle, Mrs. Jacques Heath (Lily May Peel)         35      1 Southampt~
##  5 Allen, Mr. William Henry                             35      3 Southampt~
##  6 Moran, Mr. James                                     NA      3 Queenstow
##  7 McCarthy, Mr. Timothy J                              54      1 Southampt~
##  8 Palsson, Master. Gosta Leonard                        2      3 Southampt~
##  9 Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Be~      27      3 Southampt~
## 10 Nasser, Mrs. Nicholas (Adele Achem)                  14      2 Cherbourg
## # ... with 881 more rows
```

select

O select tem várias funções úteis, como por exemplo:

- **starts_with**("cla"): seleciona colunas que começam com "cla"
- **ends_with**("ifa"): seleciona colunas que terminam com "ifa"
- **contains**("ssa"): seleciona colunas que contêm "ssa"

select

```
# Seleciona as colunas que começam com "id".
df_titanic %>%  select(starts_with("id"))
```

```
## # A tibble: 891 x 2
##    id_passageiro idade
##            <int> <dbl>
##  1             1    22
##  2             2    38
##  3             3    26
##  4             4    35
##  5             5    35
##  6             6    NA
##  7             7    54
##  8             8     2
##  9             9    27
## 10            10    14
## # ... with 881 more rows
```

select

Ao inserir o caracter **-** na frente da coluna, você estará excluindo as colunas da seleção.

```
df_titanic %>%  select(-id_passageiro, -nome)
```

```
## # A tibble: 891 x 10
##    sobreviveu classe sexo  idade irmaos_conjuge pais_criancas passagem
##    <chr>       <int> <chr> <dbl>          <int>         <int> <chr>
##  1 nao             3 masc~    22              1             0 A/5 211~
##  2 sim             1 femi~    38              1             0 PC 17599
##  3 sim             3 femi~    26              0             0 STON/O2~
##  4 sim             1 femi~    35              1             0 113803
##  5 nao             3 masc~    35              0             0 373450
##  6 nao             3 masc~    NA              0             0 330877
##  7 nao             1 masc~    54              0             0 17463
##  8 nao             3 masc~     2              3             1 349909
##  9 sim             3 femi~    27              0             2 347742
## 10 sim             2 femi~    14              1             0 237736
## # ... with 881 more rows, and 3 more variables: tarifa <dbl>,
## #   cabine <chr>, embarque <chr>
```

Desafio 3

1) Criar um objeto para salvar o resultado com as colunas nome, tarifa e classe.

2) Mostrar uma tabela com as tarifas maiores que 50 por ordem decrescente de tarifa e ordem crescente de classe. A tabela não deverá conter os campos irmaos_conjuge, pais_criancas e passagem.

mutate

Criar ou modificar colunas de uma base de dados.

Supondo que o valor da tarifa no dataset está em libras, e que 1£ = R$ 4.93, vamos descobrir qual é o valor das tarifas em reais.

```
# Altera a coluna tarifa para o valor da tarifa em reais.
tarifa_conversao <- df_titanic %>% mutate(tarifa = tarifa * 4.93)



# Retorna a coluna tarifa para o valor da época.
tarifa_conversao <- df_titanic %>% mutate(tarifa = tarifa / 4.93)
```

mutate

```
# Cria no dataset uma nova variável chamada tarifa_reais.
tarifa_conversao <- df_titanic %>% mutate(tarifa_real = tarifa * 4.93)
tarifa_conversao
```

```
## # A tibble: 891 x 13
##    id_passageiro sobreviveu classe nome  sexo  idade irmaos_conjuge
##            <int> <chr>       <int> <chr> <chr> <dbl>          <int>
##  1             1 nao             3 Brau~ masc~    22              1
##  2             2 sim             1 Cumi~ femi~    38              1
##  3             3 sim             3 Heik~ femi~    26              0
##  4             4 sim             1 Futr~ femi~    35              1
##  5             5 nao             3 Alle~ masc~    35              0
##  6             6 nao             3 Mora~ masc~    NA              0
##  7             7 nao             1 McCa~ masc~    54              0
##  8             8 nao             3 Pals~ masc~     2              3
##  9             9 sim             3 John~ femi~    27              0
## 10            10 sim             2 Nass~ femi~    14              1
## # ... with 881 more rows, and 6 more variables: pais_criancas <int>,
## #   passagem <chr>, tarifa <dbl>, cabine <chr>, embarque <chr>,
## #   tarifa_real <dbl>
```

Desafio 4

Criar uma tabela com um novo campo que contenha a tarifa em dólar seguindo essa cotação: 1£ = $ 1.31. Classifique por ordem decrescente de tarifa.

summarize

Sumariza colunas da base de dados, ou seja, resume os valores das colunas em um só valor, podendo ser a média, mediana, min, max, etc.

```
# Calcula a média da variável idade
# na.rm = TRUE remove os NAs
df_titanic %>% summarize(mean(idade, na.rm=TRUE))
```

```
## # A tibble: 1 x 1
##   `mean(idade, na.rm = TRUE)`
##                         <dbl>
## 1                        29.7
```

summarize

```r
# Calcula: número de mulheres, mediana geral da tarifa e número de passageiros.
# No caso abaixo a função sum() retorna o número de mulheres.
# A função n() mostra o número de linhas (em cada grupo) e
# costuma ser bastante usada com o summarize.
df_titanic %>%
  summarize(
    mulheres = sum(sexo == "feminino", na.rm = TRUE),
    mediana_tarifa = median(tarifa, na.rm = TRUE),
    num_passageiros = n()
)
```

```
## # A tibble: 1 x 3
##   mulheres mediana_tarifa num_passageiros
##      <int>          <dbl>           <int>
## 1      314           14.5             891
```

summarize

```r
# Filtra os passageiros homens e calcula a mediana da tarifa.
df_titanic %>%
  filter(sexo == "masculino") %>%
  summarize(
    mediana_tarifa = median(tarifa, na.rm = TRUE)
)
```

```
## # A tibble: 1 x 1
##   mediana_tarifa
##            <dbl>
## 1           10.5
```

Desafio 5

1) Calcular a média da tarifa.

2) Filtrar as passageiras mulheres e calcular a mediana da tarifa.

group_by + summarize

Agrupa as colunas de uma base de dados.

O group_by é bastante utilizado com o summarize.

```
# Agrupa pela variável sobreviveu e calcula
# o número de passageiros por grupo (sim/nao).
df_titanic %>%
  group_by(sobreviveu) %>%
  summarize(num_passageiros = n())
```

```
## # A tibble: 2 x 2
##   sobreviveu num_passageiros
##   <chr>                <int>
## 1 nao                    549
## 2 sim                    342
```

group_by + summarize

```r
# Agrupa pelo local de embarque e calcula a mediana da tarifa de cada grupo.
df_titanic %>%
  group_by(embarque) %>%
  summarize(mediana_tarifa = median(tarifa, na.rm = TRUE))
```

```
## # A tibble: 4 x 2
##   embarque    mediana_tarifa
##   <chr>                <dbl>
## 1 Cherbourg            29.7
## 2 Queenstow             7.75
## 3 Southampton          13
## 4 <NA>                 80
```

Desafios 6

1) Criar uma tabela com a quantidade de pessoas por classe.

2) Criar uma tabela com a mediana da tarifa por sexo.

Join

Com o **dplyr** também é possível fazer joins.

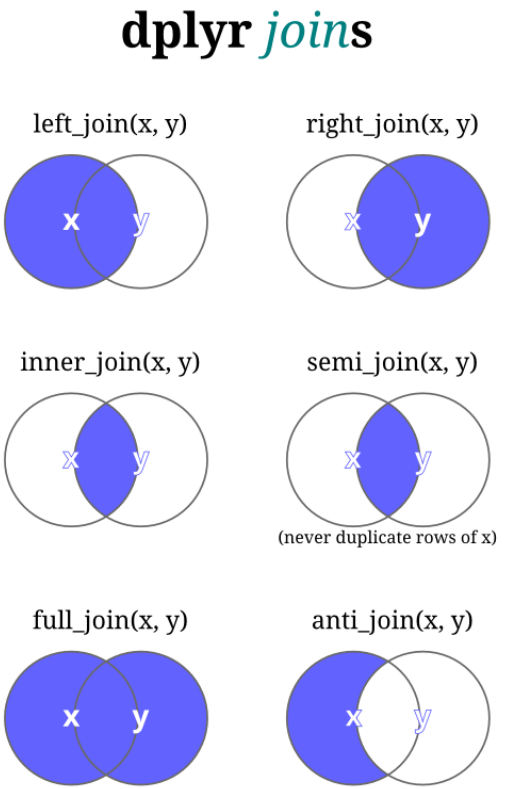

Fonte: @yutannihilation

ggplot2 - o pacote dos gráficos

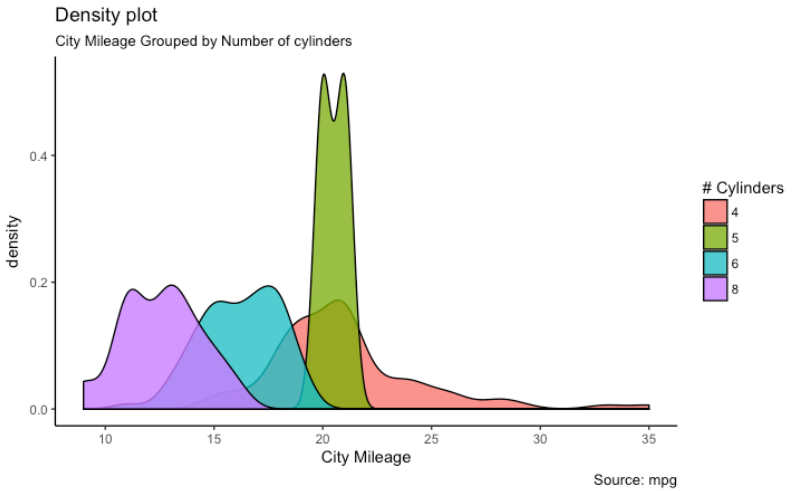

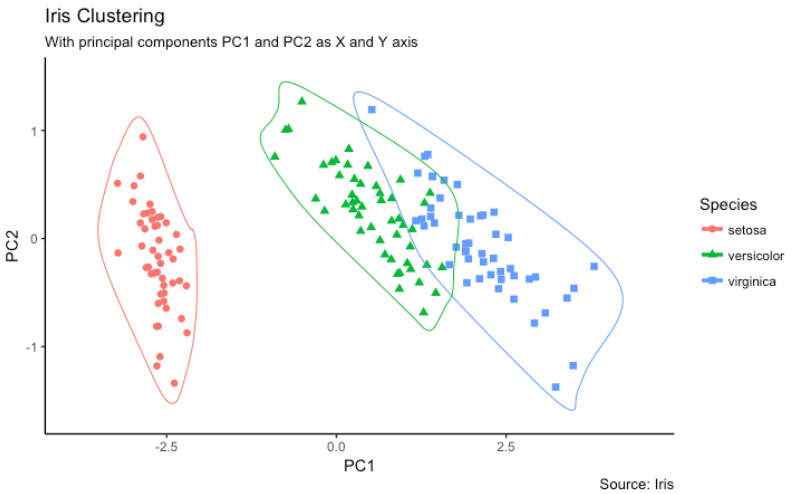

Fonte: r-statistics.co

Para aprender mais

- Livro R for Data Science
- Material do Curso-R
- Site do Tidyverse
- R-Bloggers

Referências

- https://r4ds.had.co.nz
- https://www.curso-r.com/material/
- https://www.tidyverse.org
- http://brunaw.com/slides/rladies-sp/13-08-2018/meetup.html#1
- https://bookdown.org/wevsena/curso_r_tce/curso_r_tce.html
- https://rstudio-pubs-static.s3.amazonaws.com/279878_c7634fb5fe9e40b7abc7c35aa724a2a0.html
- https://analisereal.com/tag/introducao-a-analise-de-dados-com-o-r-2/
- http://r-statistics.co/Top50-Ggplot2-Visualizations-MasterList-R-Code.html

A apresentação foi feita em xaringan, um pacote do R! :)

If you want to go fast,

go alone.

If you want to go far,

go together.

- African Proverb -

Muito obrigada!

R-Ladies São Paulo